

Analyse de données e commerce

Projet final Data Engineer, Spark et Scala
Dakar Institute of Technology

GROUPE 9

ABOUTA EUDOXIE BAMBA ISSOUF AHOGA JOSIAS

Année académique 2025-2026

- Contexte et problématique
- Architecture et organisation
- Ingestion et qualité des données
- Transformations et enrichissement
- Analytique métier et performance
- Démonstration et industrialisation
- Limites, conclusion et perspectives

- Quatre fichiers de formats différents, volontairement sales, décrivent la même activité commerciale.
- 138 047 transactions tiennent sur un poste de travail : la difficulté n'est pas la taille, c'est la fiabilité de ce qu'on en tire.
- Un montant invalide fausse le chiffre d'affaires, la commission du marchand et son classement.

Traçabilité

Chaque ligne écartée porte son motif. Tout chiffre présenté se remonte jusqu'à sa ligne source.

Les quatre sources

Fichier	Lignes	Format	Stratégie de lecture
transactions.csv	138 047	CSV	Schéma explicite, mode FAILFAST
users.json	12 000	JSON	Schéma typé, champ tableau imbriqué
products.parquet	6 000	Parquet	Répertoire de douze fichiers
merchants.csv	600	CSV	Inférence, puis conversions explicites

Configuration externalisée

Chemins, seuils et paramètres Spark proviennent de `application.conf`. Aucune valeur codée en dur.

Bronze	Silver	Gold
Lecture multi format Schéma explicite et typage FAILFAST sur l'illisible DataIngestion	Rejets conservés et motivés Jointures expliquées Fenêtres et UDF temporelle DataValidation, TimeFeatures	Quatorze rapports métier Tableau de bord HTML Durées par étape Analytics, DashboardReport

Socle transverse

`application.conf`, cache et diffusion, `MainApp` pour l'orchestration et le chronométrage, conteneur et intégration continue.

Organisation de l'équipe

Membre	Rôle	Parties	Relu par
ABOUTA Eudoxie	Ingestion et plateforme	1, 2 et 7	Issouf et Josias
BAMBA Issouf	Transformations	3	Eudoxie
AHOGA Josias	Analytique et performance	4, 5 et 6	Issouf et Eudoxie

Séparation par fichier

Chaque fichier a un propriétaire unique.

Relecture tracée

Chaque module est relu par un autre membre.
Date, relecteur et remarques sont consignés.

ABOUTA Eudoxie

```
def transactions(): Dataset[Transaction] = read("transactions") {  
    spark.read.option("header", true).option("mode", "FAILFAST")  
        .schema(Encoders.product[Transaction].schema)  
        .csv(path("transactions")).as[Transaction]  
}
```


Montant absent

Il reste nul jusqu'à la validation, il n'est jamais remplacé par zéro.

Lecture immédiate

Une action `count` force la lecture dès l'ingestion.

ABOUTA Eudoxie



Orphelines : 400 utilisateurs,
300 produits, 250 marchands.

Jeu	Rejets	Taux
transactions	1 890	1,37 %
users	345	2,88 %
products	179	2,98 %
merchants	14	2,33 %

Réconciliation des volumes

$138\,047 = 1\,890 \text{ rejets} + 11\,406 \text{ références non enrichissables} + 124\,751 \text{ analysées.}$

BAMBA Issouf

```
udf((value: String) => features(value, settings).orNull)

def dayPeriod(hour: Int, s: TimeSettings): String =
  if (hour < s.morningStart || hour >= s.nightStart) "Night"
  else if (hour < s.afternoonStart)                  "Morning"
  else if (hour < s.eveningStart)                     "Afternoon"
  else                                                "Evening"
```

Robustesse

Une chaîne nulle, vide ou mal formée renvoie null. Le 29 février 2025 est rejeté.

Découpage horaire

Morning 06h à 11h59, Afternoon 12h à 17h59, Evening 18h à 21h59, Night 22h à 05h59.

BAMBA Issouf

```
val glissante = Window.partitionBy("user_id").orderBy("epoch_seconds")  
                    .rangeBetween(-7 * 86400L + 1L, 0L)  
  
size(collect_set(col("transaction_date")).over(glissante))
```

transaction_rank
rolling_amount_7d
active_days_7d
days_since_previous
age_group

Colonnes ajoutées à chaque transaction.

Fenêtre en secondes

La borne est en secondes, pas en nombre de lignes.

BAMBA Issouf


- Montant supérieur de 300 % au panier moyen historique du client
- Achat entre 22h00 et 05h59
- Moins de cinq minutes depuis l'achat précédent
- Moyen de paiement déclaré en CRYPTO

Chiffre clé

3 760 transactions signalées, soit 3,01 % du périmètre, avec au moins deux signaux sur quatre.

Performance par marchand

AHOGA Josias



Classements


dense_rank par catégorie et par région.

Commission par ligne

Montant multiplié par le taux du marchand.
TechStore 225 : 42 889,54 EUR.

Cohortes et rétention

AHOGA Josias



Horizons non observables

Une cohorte de novembre 2025 n'a pas de M+3 observable. Ces horizons sont exclus du classement.

Meilleure rétention à trois mois

Cohorte de juin 2025 : 118 clients encore actifs sur 310, soit 38,06 %.

Segmentation RFM

AHOGA Josias


Segment calculé	VIP	Premium	Standard	Budget
Champions	451	613	272	32
Clients fidèles	266	854	1 305	816
À risque	287	726	866	317
Nouveaux	18	146	618	724
Perdus	2	67	653	1 160

Lecture de la matrice

451 Champions déclarés VIP, 1 160 Perdus déclarés Budget. 32 Budget se comportent en Champions, 2 VIP sont perdus.

AHOGA Josias

- cache sur les résultats réutilisés
- persist sur les transactions enrichies
- broadcast des trois référentiels
- exécution adaptative sur la session
- unpersist dans un finally



Quatre exécutions du même code,
même machine, même journée.

Variabilité mesurée

37 % d'écart entre la plus rapide et la plus lente.

```
spark-submit --master 'local[2]' --driver-memory 3g  
--class com.ecommerce.analytics.MainApp  
dist/ecommerce-analytics.jar all
```

124 751	transactions analysées	10 193	clients uniques
49,90 M EUR	de chiffre d'affaires	399,98 EUR	de panier moyen
3,01 %	de transactions signalées	14	rapports produits

Restitution

Une commande produit les quatorze rapports et une page HTML autonome, en thème clair et en thème sombre.

Environnement figé

`Dockerfile` et `docker-compose` figent Spark 3.5.6, Scala 2.12 et Java 17. `Makefile` sous Linux et macOS, `make.ps1` sous Windows.

Vérification automatique

GitHub Actions compile, teste et empaquette à chaque `push`. Vingt cas de régression couvrent les frontières et les règles métier.

20 / 20 tests au vert

108 s pipeline complet

0 chemin codé en dur

Limite	Précision
Données synthétiques	Générées par le script fourni. Les conclusions démontrent une méthode.
Mesure exploratoire	Un passage par mode, sur un poste partagé, avec 37 % de variabilité.
Cluster documenté, non exécuté	Commandes HDFS, YARN et <code>cluster.conf</code> figurent au README.
Détection pédagogique	Quatre règles seuillées ne constituent pas un modèle de fraude validé.
Conteneur non construit	Le <code>Dockerfile</code> s'appuie sur les images officielles.

Bilan

Les 138 047 lignes lues se reconstituent exactement. Chaque rejet porte son motif. Le même code passe du poste au cluster sans être réécrit.

Perspectives

- Répéter le benchmark en alternant l'ordre des modes
- Construire et éprouver l'image du conteneur
- Exécuter le pipeline sur un cluster réel
- Mesurer la couverture de lignes des tests

Merci de votre attention