

GROUPE 9

ANALYSE DE DONNÉES E COMMERCE

Un pipeline Spark qui explique ses rejets, mesure la fidélité et publie lui même son tableau de bord.

ABOUTA Eudoxie Ingestion et plateforme

BAMBA Issouf Transformations

AHOGA Josias Analytique et performance

124 751

transactions analysées

Spark 3.5.6

Scala 2.12

Java 17

Le problème posé

Quatre fichiers hétérogènes, volontairement sales, à transformer en décisions défendables

Pas un problème de volume

138 047 transactions tiennent sur un poste. Le vrai sujet est la confiance.

138 047

LIGNES LUES

Un chiffre faux coûte cher

Un montant invalide fausse le chiffre d'affaires, la commission et le classement.

13 296

LIGNES ÉCARTÉES

Notre principe

Aucune ligne ne disparaît en silence. Chaque rejet porte son motif.

124 751

TRANSACTIONS ANALYSÉES

$$138\,047 = 1\,890 + 11\,406 + 124\,751$$

Un format différent par source : le pipeline doit typer, pas deviner

Fichier	Lignes	Format	Stratégie de lecture
transactions.csv	138 047	CSV	Schéma explicite, mode FAILFAST
users.json	12 000	JSON	Schéma typé, champ tableau imbriqué
products.parquet	6 000	Parquet	Répertoire de douze fichiers, schéma porté
merchants.csv	600	CSV	Inférence, puis conversions explicites

Tous les chemins proviennent de `application.conf`. Aucun chemin, aucun seuil et aucun paramètre Spark n'est codé en dur.

Trois couches, trois propriétaires, un contrat de données à chaque frontière

BRONZE

Données brutes

Lecture multi format
Schéma explicite et typage
FAILFAST sur l'illisible

`DataIngestion.scala`

ABOUTA Eudoxie

SILVER

Validées et enrichies

Rejets conservés et motivés
Jointures expliquées
Fenêtres et UDF temporelle

`DataValidation, TimeFeatures`

ABOUTA Eudoxie et BAMBA Issouf

GOLD

Rapports métier

Quatorze rapports CSV et Parquet
Tableau de bord HTML autonome
Durées par étape

`Analytics, DashboardReport`

AHOGA Josias

Socle transverse application.conf ■ cache et broadcast ■ MainApp : orchestration et chronométrage ■ conteneur et CI

Trois rôles exclusifs, des fichiers séparés, une relecture croisée obligatoire

Membre	Rôle	Parties	Relu par
ABOUTA Eudoxie	Ingestion et plateforme	1, 2 et 7	Issouf et Josias
BAMBA Issouf	Transformations	3	Eudoxie
AHOGA Josias	Analytique et performance	4, 5 et 6	Issouf et Eudoxie

Séparation par fichier

La structure imposée attribue un fichier à un seul propriétaire. Trois personnes travaillent en parallèle sans conflit Git.

La relecture laisse une trace

Chaque module est relu par quelqu'un d'autre que son auteur. Date, relecteur et remarques sont dans `CONTRIBUTIONS.md`.

```
def transactions(): Dataset[Transaction] = read("transactions") {  
  spark.read.option("header", true).option("mode", "FAILFAST")  
    .schema(Encoders.product[Transaction].schema)  
    .csv(path("transactions")).as[Transaction]  
}  
  
case class Transaction(transaction_id: String, ...,  
  amount: Option[Double], timestamp: String, ...)
```

Option, et non zéro

Un montant absent reste nul jusqu'à la validation. Le remplacer par zéro rendrait le rejet inexplicable.

count déclenche la lecture

Spark est paresseux : sans action, une erreur de fichier remonterait au milieu du pipeline.

ABOUTA Eudoxie Membre A

L'ENTONNOIR



REJETS PAR JEU

Jeu	Rejets	Taux
transactions	1 890	1,37 %
users	345	2,88 %
products	179	2,98 %
merchants	14	2,33 %

Références orphelines : 400 utilisateurs, 300 produits, 250 marchands.

L'égalité que nous savons défendre

$138\,047 = 1\,890 \text{ rejets} + 11\,406 \text{ références non enrichissables} + 124\,751 \text{ analysées}$

```
udf((value: String) => features(value, settings).orNull)

def dayPeriod(hour: Int, s: TimeSettings): String =
  if (hour < s.morningStart || hour >= s.nightStart) "Night"
  else if (hour < s.afternoonStart)                  "Morning"
  else if (hour < s.eveningStart)                     "Afternoon"
  else                                                "Evening"
```

Robuste par construction

Une chaîne nulle, vide ou mal formée renvoie null. Le 29 février 2025 est rejeté, pas décalé.

Conventions assumées

Le sujet ne dit rien de minuit à six heures : nous classons en Night. L'heure 17 reste ouvrée.

Morning 06h00 à 11h59 ▪ **Afternoon** 12h00 à 17h59 ▪ **Evening** 18h00 à 21h59
▪ **Night** 22h00 à 05h59


```
val glissante = Window.partitionBy("user_id").orderBy("epoch_seconds")
                    .rangeBetween(-7 * 86400L + 1L, 0L)

size(collect_set(col("transaction_date")).over(glissante)) // jours actifs
```

rangeBetween, pas rowsBetween

La borne est en secondes. Trois achats dans la journée ne font pas sortir les autres de la fenêtre.

Jours distincts

collect_set élimine les doublons de date : deux achats le même jour comptent pour un.

CE QUE LA TRANSACTION ENRICHIE GAGNE

transaction_rank	Rang de l'achat chez ce client
rolling_amount_7d	Montant cumulé sur sept jours
active_days_7d	Jours d'achat distincts, et is_active
days_since_previous	Délai depuis l'achat précédent, avec lag
age_group	Jeune, Adulte, Âge Moyen, Senior

BAMBA Issouf Membre B

01 Montant hors norme

Plus de 300 % au dessus du panier moyen historique du client.

02 Achat nocturne

La transaction tombe entre 22h00 et 05h59.

03 Rafale

Moins de cinq minutes depuis l'achat précédent du même client.

04 Paiement en crypto

Le moyen de paiement déclaré est CRYPTO.

3 760

TRANSACTIONS SIGNALÉES

≥ 2

SIGNAUX EXIGÉS


0

ACCUSATION

Soit 3,01 % du périmètre. Le seuil est un paramètre de configuration. Un signal n'est pas une preuve : le résultat oriente un contrôle humain.

AHOGA Josias Membre C

TROIS PREMIERS MARCHANDS, CHIFFRE D'AFFAIRES



Deux classements, pas un

dense_rank par catégorie et par région. Un marchand peut dominer sa région sans dominer sa catégorie.


Commission par ligne

Montant multiplié par le taux du marchand, puis agrégé et arrondi au centime.

TechStore 225 366 transactions ▪ 337 clients uniques ▪ commission 42 889,54 EUR

AHOGA Josias Membre C

PROFIL DE LA MEILLEURE COHORTE



Meilleure rétention à trois mois
310, soit **38,06 %**

Cohorte de juin 2025 : 118 clients encore actifs sur

Un mois de naissance

Chaque client appartient au mois de son premier achat. M+0 vaut donc toujours cent pour cent.

Le piège évité

Une cohorte de novembre 2025 n'a pas de M+3 observable. La compter comme un échec fausserait le classement.

AHOGA Josias Membre C

Segment calculé	VIP	Premium	Standard	Budget
Champions	451	613	272	32
Clients fidèles	266	854	1 305	816
À risque	287	726	866	317
Nouveaux	18	146	618	724
Perdus	2	67	653	1 160

Scores par quintiles

ntile(5) sur récence, fréquence et montant. Égalités départagées par identifiant.

Le vrai résultat

451 Champions déclarés VIP,
1 160 Perdus déclarés Budget :
le comportement valide la
segmentation.

Les exceptions


32 Budget se comportent en
Champions, 2 VIP sont perdus.
À traiter en premier.

AHOGA Josias Membre C

CE QUE NOUS AVONS ACTIVÉ

- cache sur les résultats réutilisés
- `persist(MEMORY_AND_DISK_SER)` sur les transactions enrichies
- broadcast des trois référentiels
- exécution adaptative sur la session
- `unpersist` dans un `finally`

QUATRE EXÉCUTIONS DU MÊME CODE



37 % d'écart, sur la même machine, le même jour.

L'honnêteté de la mesure

En dessous de 30 % d'écart, sur ce matériel, une différence ne prouve rien.

DÉMONSTRATION

Le pipeline publie son propre tableau de bord

Une seule commande produit les quatorze rapports et une page HTML autonome, en thème clair et en thème sombre.

```
spark-submit  
  --master 'local[2]' --driver-memory 3g  
  --class com.ecommerce.analytics.MainApp  
  dist/ecommerce-analytics.jar all
```

124 751

TRANSACTIONS ANALYSÉES

49,90 M EUR

CHIFFRE D'AFFAIRES

10 193

CLIENTS UNIQUES

399,98 EUR

PANIER MOYEN

3,01 %

SIGNALÉES

Ce qui rend le projet reproductible

Un tiers doit pouvoir rejouer notre pipeline sans nous

Conteneur

Dockerfile et docker-compose figent
Spark 3.5.6, Scala 2.12 et Java 17.

Commandes unifiées

Makefile sous Linux et macOS, `make.ps1`
sous Windows, scripts confinés pour macOS.

Intégration continue

GitHub Actions compile, teste et empaquette
à chaque push.

Régression

Vingt cas isolés couvrant les frontières et les
règles métier, rapport JUnit exploitable.

20 / 20

CAS DE RÉGRESSION AU VERT

108 s

PIPELINE COMPLET EN LOCAL

0

CHEMIN CODÉ EN DUR

Ce que nous ne prétendons pas avoir prouvé

Déclarer les limites vaut mieux que les laisser découvrir

Limite	Précision
Les données sont synthétiques	Générées par le script du sujet. Les conclusions démontrent une méthode.
La mesure n'est pas une expérience	Un passage par mode, sur un poste partagé, avec 37 % de variabilité.
Le cluster est documenté, pas exécuté	Commandes HDFS, YARN et <code>cluster.conf</code> figurent au README.
La détection de fraude est pédagogique	Quatre règles seuillées ne constituent pas un modèle validé.
Le conteneur reste à éprouver	Le <code>Dockerfile</code> s'appuie sur les images officielles, sans construction.

Avec une semaine de plus : répéter le benchmark en alternant l'ordre, construire l'image Docker, mesurer la couverture de lignes.

Ce que ce pipeline établit

- Les 138 047 lignes lues se reconstituent exactement.
- Chaque rejet porte son motif, et tout chiffre remonte à sa ligne source.
- Les résultats sont exploitables : rétention de 38,06 %, 451 Champions, 3 760 transactions à contrôler.
- Le même code passe du poste au cluster sans être réécrit.
- Les limites sont écrites, la mesure est publiée telle quelle.

MERCI

DE VOTRE ATTENTION

Groupe 9 ■ ABOUTA Eudoxie ■ BAMBA Issouf ■ AHOGA Josias